

TRABALHO I

Balanceador de Carga para um Sistema Distribuído

Rafael Carro Gaudim 240879, Douglas Henrique Pereira 245202

I. RESUMO

NESSE relatório iremos desenvolver e analisar um modelo analítico para uma política de escolha aleatória num load balancer com filas do **M/M/1**. Também iremos comparar esse modelo com as simulações desenvolvidas para analisar as políticas dos tipos: **Escolha Aleatória**, **Round-Robin** e **Fila Mais Curta**.

II. ARQUITETURA

Primeiramente, iremos descrever a arquitetura do Load Balancer, dos servidores, da geração de tráfego e das políticas escolhidas para a simulação.

A. Arquitetura do Load Balancer

A arquitetura implementada é composta por um gerador de requisições, um Load Balancer e um conjunto de servidores. O gerador cria requisições de acordo com uma distribuição de Poisson e as encaminha para o Load Balancer. Cada requisição recebe um identificador sequencial.

O Load Balancer mantém uma lista dos servidores disponíveis e seleciona um deles para cada requisição recebida, de acordo com a política configurada. Após a seleção, a requisição é iniciada no servidor correspondente. A simulação é implementada utilizando a biblioteca SimPy, que permite representar os servidores como recursos concorrentes e controlar a passagem do tempo.

B. Descrição dos servidores

Cada servidor é representado pela classe `Server` e possui um nome, uma capacidade máxima de processamento simultâneo e um parâmetro λ associado ao tempo de processamento. A capacidade determina quantas requisições podem ser processadas ao mesmo tempo. Caso todos os recursos estejam ocupados, as novas requisições são armazenadas na fila do servidor.

O tempo de processamento de cada requisição é obtido por meio de uma distribuição exponencial, parametrizada pelo valor $\lambda_{\text{processamento}}$. Assim, servidores com diferentes parâmetros podem apresentar tempos médios de processamento distintos. Durante a execução, são registrados os instantes de início e término de cada requisição, a quantidade de recursos ocupados e o tamanho da fila.

C. Parametrização do tráfego

O tráfego é gerado pela função `request_generator`. O intervalo entre duas chegadas consecutivas é obtido a partir de uma distribuição exponencial, com parâmetro λ_{chegada} . Consequentemente, as requisições chegam ao sistema segundo um processo de Poisson.

A intensidade do tráfego pode ser controlada alterando-se o valor de λ_{chegada} . Valores maiores representam intervalos médios menores entre chegadas e, portanto, uma carga mais elevada sobre os servidores. Além desse parâmetro, a simulação permite configurar o número de servidores, a capacidade de cada servidor, o parâmetro de processamento, a política do Load Balancer, o tempo total da simulação e a semente utilizada para a geração de números aleatórios.

D. Políticas

Foram implementadas três políticas de distribuição de requisições:

- **Random:** seleciona aleatoriamente um dos servidores. Essa política não considera o estado atual das filas ou a quantidade de requisições em processamento. Embora seja simples, pode produzir uma distribuição desequilibrada das requisições.
- **Round Robin:** distribui as requisições de forma sequencial entre os servidores. Quando o último servidor é utilizado, a seleção retorna ao primeiro. Essa política tende a distribuir uniformemente as requisições, mas não considera a carga atual nem o tempo de processamento de cada servidor.
- **Shortest Queue:** seleciona o servidor com a menor quantidade de requisições em processamento. Em caso de empate, é selecionado o servidor com a menor fila de espera. Essa política utiliza o estado atual dos servidores para encaminhar as requisições ao servidor aparentemente menos carregado.

A política utilizada é definida por meio de uma enumeração, permitindo selecionar diferentes estratégias sem alterar a estrutura principal da simulação. Dessa forma, é possível comparar o comportamento das políticas sob diferentes taxas de chegada, tempos de processamento, capacidades dos servidores e sementes aleatórias.

III. MODELAGEM ANALÍTICA

Nesta seção, utilizaremos conceitos de Teoria de Filas para desenvolver a modelagem analítica do sistema considerando a política de escolha aleatória.

A. Parâmetros do Sistema

O sistema é composto por três servidores *single-thread* homogêneos, com uma fila FCFS (*First Come, First Served*) ilimitada. As requisições são representadas como um processo de Poisson de taxa λ . O tempo de serviço é modelado por uma distribuição exponencial de média $1/\mu$.

B. Independência dos Servidores

Proposição: Sob a política aleatória, as requisições em cada servidor é um processo de Poisson de taxa $\lambda_i = \lambda/3$ e os servidores são processos independentes entre si.

Prova: Seja $\{A(t)\}$ um processo de Poisson de taxa λ que representa o processo de chegada de requisições. Cada requisição é redirecionada para o servidor i com probabilidade p_i e $\sum_i p_i = 1$. Queremos mostrar que $\{A_i(t)\}$ são processos de Poisson independentes.

$$\begin{aligned}
 P(A_i(t) = n_i, \forall i) &= P\left[(A_i(t) = n_i, \forall i) \wedge \sum_{i=1}^N n_i = n\right] \\
 &= P\left[(A_i(t) = n_i, \forall i) \mid A(t) = \sum_{i=1}^N n_i\right] \cdot \\
 &\quad P\left[A(t) = \sum_{i=1}^N n_i\right] \\
 &= \binom{n}{n_1, n_2, \dots, n_N} \prod_{i=1}^N p_i^{n_i} \cdot \frac{e^{-\lambda t} (\lambda t)^n}{n!} \\
 &= \frac{n!}{n_1! n_2! \dots n_N!} \cdot \frac{e^{-\lambda t} (\lambda t)^n}{n!} \cdot \prod_{i=1}^N p_i^{n_i} \\
 &= \prod_{i=1}^N \frac{e^{-p_i \lambda t} (p_i \lambda t)^{n_i}}{n_i!} = \text{Poisson}(\lambda_i)^N
 \end{aligned}$$

Logo, no caso de $N = 3$ e $p_i = 1/3$ (escolha aleatória), as chegadas em cada servidor são processos de Poisson de taxa $\lambda_i = \lambda/3$ independentes.

C. Fila M/M/1 e Distribuição Estacionária

Como foi visto na seção 3.B, o sistema de chegadas em cada servidor é um processo de Poisson, e o tempo de serviço é uma distribuição exponencial. Nesse caso, ambos são *memoryless* por seguirem uma distribuição exponencial. Logo a fila de cada servidor é **M/M/1** pela notação de *Kendall*.

A fila de cada servidor enche com taxa λ_i e esvazia a uma taxa μ . Então, a probabilidade (P_k) de a fila estar no estado k será:

$$P_k = \frac{\lambda_i}{\mu} P_{k-1} = \rho \cdot P_{k-1}, \text{ dado } \sum_{k=0}^{\infty} P_k = 1$$

Com isso, obtemos: $P_0 = 1 - \rho$ e $P_k = (1 - \rho)\rho^k$. Com as probabilidades de estar em cada estado, podemos calcular outras métricas da fila de cada servidor como ($U_i, E[N_i], E[T_Q], E[R]$), respectivamente, utilidade, número

esperado de requisições no servidor, tempo esperado na fila, tempo esperado de resposta.

- Utilidade é a porcentagem do tempo que a fila está ocupada: $U_i = 1 - P_0$
- $E[N_i] = \sum_{k=0}^{\infty} k P_k = \sum_{k=0}^{\infty} k (1 - \rho) \rho^k = \frac{\rho}{(1 - \rho) \sum_{k=0}^{\infty} \rho^k} = \frac{\rho}{1 - \rho}$
- $E[T_Q] = E[T] - E[S] = E[N_i]/\lambda_i - 1/\mu = \frac{\rho}{\mu - \lambda_i}$
- $E[R] = E[T_Q] + E[S] = \frac{\rho}{\mu - \lambda_i} + 1/\mu = \frac{1}{\mu - \lambda_i}$

D. Verificação da Lei de Little

A Lei de Little estabelece que, em um sistema estável em regime estacionário,

$$E[N] = X \cdot E[R], \quad (1)$$

onde $E[N]$ representa o número médio de requisições no sistema, X representa a vazão (*throughput*) e $E[R]$ representa o tempo médio de resposta.

Como o sistema não descarta requisições, espera-se que, em regime estacionário, a vazão total seja aproximadamente igual à taxa de chegada:

$$X \approx \lambda. \quad (2)$$

Para verificar experimentalmente a Lei de Little, foi calculado o produto $XE[R]$ utilizando os valores obtidos na simulação e comparado esse resultado com o número médio de requisições observado diretamente no sistema.

TABLE I
VERIFICAÇÃO DA LEI DE LITTLE PARA A POLÍTICA ALEATÓRIA.

λ	X	$E[R]$	$XE[R]$	$E[N]_{\text{sim}}$
0.6	0.6011	1.2299	0.7393	0.7402
1.2	1.2010	1.6670	2.0020	2.0040
1.8	1.7937	2.4824	4.4527	4.4575
2.4	2.3963	5.1328	12.2995	12.3544
2.7	2.6924	10.1819	27.4134	27.4855

A mesma verificação pode ser realizada para as políticas Round-Robin e fila mais curta.

Os resultados mostram uma forte concordância entre $E[N]_{\text{sim}}$ e $XE[R]$ para todas as políticas e valores de λ . O maior erro relativo observado foi de aproximadamente 0.50%, para a política Round-Robin com $\lambda = 2.7$. Portanto, dentro da variabilidade introduzida pela simulação, os resultados confirmam experimentalmente a validade da Lei de Little para o sistema analisado.

Além disso, observa-se que a vazão medida permanece próxima da taxa de chegada em todos os experimentos. Por exemplo, para $\lambda = 1.8$, as vazões observadas foram 1.7937, 1.7933 e 1.7961 para as políticas aleatória, Round-Robin e fila mais curta, respectivamente. Isso é consistente com o comportamento esperado de um sistema estável no qual as requisições são processadas sem perdas.

TABLE II
VERIFICAÇÃO DA LEI DE LITTLE PARA AS TRÊS POLÍTICAS.

λ	Política	$XE[R]$	$E[N]_{\text{sim}}$	Erro relativo
0.6	Aleatória	0.7393	0.7402	0.124%
0.6	Round-Robin	0.6423	0.6430	0.112%
0.6	Fila curta	0.6132	0.6138	0.103%
1.2	Aleatória	2.0020	2.0040	0.100%
1.2	Round-Robin	1.5604	1.5614	0.062%
1.2	Fila curta	1.3686	1.3694	0.057%
1.8	Aleatória	4.4527	4.4575	0.108%
1.8	Round-Robin	3.2705	3.2733	0.085%
1.8	Fila curta	2.5361	2.5379	0.074%
2.4	Aleatória	12.2995	12.3544	0.444%
2.4	Round-Robin	8.2199	8.2361	0.198%
2.4	Fila curta	5.5164	5.5210	0.082%
2.7	Aleatória	27.4134	27.4855	0.263%
2.7	Round-Robin	16.7548	16.8387	0.498%
2.7	Fila curta	11.5716	11.5855	0.120%

E. Caso sobrecarregado: $\lambda = 3.3$

Para $\mu = 1$, a capacidade total de processamento dos três servidores é

$$\mu_{\text{total}} = 3\mu = 3. \quad (3)$$

Como $\lambda = 3.3 > 3$, o sistema está sobrecarregado e não possui regime estacionário. Na política aleatória, por exemplo,

$$\lambda_i = \frac{3.3}{3} = 1.1 \Rightarrow \rho = \frac{\lambda_i}{\mu} = 1.1 > 1. \quad (4)$$

Logo, as expressões de regime estacionário da fila M/M/1, como $E[N_i] = \rho/(1 - \rho)$ e $E[R] = 1/(\mu - \lambda_i)$, não são aplicáveis.

Os resultados da simulação, apresentados na Tabela III, mostram esse comportamento.

TABLE III
RESULTADOS DA SIMULAÇÃO PARA $\lambda = 3.3$.

Política	X	$E[R]$	$E[N]$	$\bar{U}$
Aleatória	2.944	280.124	917.841	99.96%
Round-Robin	2.963	252.955	827.766	99.98%
Fila curta	2.954	268.414	875.640	99.98%

A vazão permanece abaixo da taxa de chegada de 3.3, enquanto os servidores permanecem praticamente 100% ocupados. Como a capacidade total é inferior à taxa de chegada, as requisições se acumulam nas filas, resultando em um grande número médio de requisições no sistema e em tempos de resposta elevados.

Portanto, o experimento com $\lambda = 3.3$ evidencia o limite de estabilidade do sistema: quando $\lambda > 3\mu$, não é possível atingir um regime estacionário e o tamanho das filas tende a crescer com o tempo.

IV. COMPARAÇÃO DAS POLÍTICAS

A partir do resultado obtido anteriormente, para a política de escolha aleatória cada servidor pode ser modelado como uma fila M/M/1 com taxa de chegada $\lambda_i = \lambda/3$. Considerando $\mu = 1$, o tempo médio de resposta esperado para essa política é

$$E[R]_{\text{aleatória}} = \frac{1}{\mu - \lambda/3} = \frac{1}{1 - \lambda/3}. \quad (5)$$

Esse resultado é utilizado como referência analítica para os resultados obtidos por simulação.

A Figura 1 apresenta a curva analítica de $E[R]$ para a política aleatória juntamente com os valores obtidos por simulação para as três políticas. As barras de erro representam os intervalos de confiança de 95




Fig. 1. Comparação do tempo médio de resposta para as três políticas. A curva tracejada representa o resultado analítico da política aleatória e as curvas sólidas representam os resultados obtidos por simulação, com barras de erro correspondentes aos intervalos de confiança de 95%.

A Tabela IV apresenta os valores numericamente. Para os resultados simulados, o valor após o símbolo $\pm$ corresponde à semi-amplitude do intervalo de confiança de 95

TABLE IV
TEMPO MÉDIO DE RESPOSTA DAS POLÍTICAS.

λ	Análítico	Aleatória	Round-Robin	Fila curta
0.6	1.250	1.230 ± 0.019	1.064 ± 0.019	1.017 ± 0.016
1.2	1.667	1.667 ± 0.027	1.299 ± 0.021	1.138 ± 0.012
1.8	2.500	2.482 ± 0.067	1.824 ± 0.053	1.412 ± 0.020
2.4	5.000	5.133 ± 0.409	3.438 ± 0.120	2.303 ± 0.114
2.7	10.000	10.182 ± 1.209	6.239 ± 0.699	4.295 ± 0.361

Observa-se uma boa concordância entre os resultados simulados da política aleatória e os valores previstos pelo modelo analítico. Para $\lambda = 0.6$, o valor analítico é 1.250, enquanto o valor simulado é 1.230 ± 0.019 . Para $\lambda = 1.2$, ambos apresentam valor de aproximadamente 1.667. As diferenças tornam-se mais perceptíveis para valores maiores de λ , especialmente para $\lambda = 2.4$ e $\lambda = 2.7$.

Esse comportamento está relacionado ao aumento da utilização dos servidores. Na política aleatória, cada servidor possui taxa de chegada $\lambda/3$, de modo que sua utilização é

$$\rho = \frac{\lambda}{3\mu} = \frac{\lambda}{3}. \quad (6)$$

Assim, conforme λ se aproxima de 3, a utilização dos servidores se aproxima de 1 e o tempo médio de resposta aumenta rapidamente. Para $\lambda = 2.7$, por exemplo, temos $\rho = 0.9$ e o modelo analítico resulta em $E[R] = 10$. A maior

utilização também provoca maior variabilidade nos resultados da simulação, o que pode ser observado pelo aumento dos intervalos de confiança.

Além da comparação com o modelo analítico, os resultados permitem comparar diretamente as três políticas. Para todos os valores de λ analisados, os resultados apresentam a relação

$$E[R]_{\text{fila curta}} < E[R]_{\text{Round-Robin}} < E[R]_{\text{aleatória}} \quad (7)$$

A política aleatória não considera o estado atual dos servidores. Dessa forma, uma requisição pode ser encaminhada para um servidor que esteja momentaneamente mais carregado enquanto outro servidor possui uma fila menor.

A política Round-Robin distribui as requisições de maneira cíclica entre os servidores, proporcionando uma distribuição aproximadamente uniforme das chegadas. Entretanto, essa política também não considera o estado instantâneo das filas. Consequentemente, um servidor que esteja temporariamente mais carregado pode receber uma nova requisição mesmo quando outro servidor possui uma fila menor.

Por outro lado, a política de escolha da fila mais curta utiliza o estado atual do sistema para realizar o encaminhamento. A requisição é direcionada para um servidor que possui uma das menores filas, reduzindo o desbalanceamento entre os servidores e, consequentemente, o tempo de espera.

A diferença entre as políticas aumenta conforme a taxa de chegada cresce. Para $\lambda = 0.6$, os tempos médios de resposta obtidos para as políticas aleatória, Round-Robin e fila mais curta são, respectivamente, 1.230, 1.064 e 1.017. Para $\lambda = 2.7$, esses valores passam para 10.182, 6.239 e 4.295. Portanto, o efeito da estratégia de escalonamento torna-se mais significativo quando o sistema opera com maior utilização.

Esse comportamento ocorre porque, em condições de maior carga, uma distribuição inadequada das requisições produz filas maiores e aumenta significativamente o tempo de espera. A política de fila mais curta utiliza informações sobre o estado atual do sistema para reduzir esse desbalanceamento, enquanto as políticas aleatória e Round-Robin não consideram diretamente o tamanho atual das filas.

V. CONCLUSÃO

Neste trabalho foi desenvolvido e analisado um sistema distribuído composto por um balanceador de carga e três servidores, com o objetivo de avaliar diferentes políticas de distribuição de requisições. Foram consideradas as políticas de escolha aleatória, Round-Robin e escolha da fila mais curta, avaliando seu comportamento para diferentes taxas de chegada.

Os resultados obtidos por simulação mostraram que a política aleatória apresentou boa concordância com o modelo analítico utilizado como referência. Para essa política, cada servidor pode ser modelado como uma fila $M/M/1$ com taxa média de chegada $\lambda/3$, permitindo obter analiticamente o tempo médio de resposta. A comparação entre os valores analíticos e simulados apresentou resultados próximos, validando a implementação da simulação.

Também foi possível observar que a política utilizada pelo balanceador possui impacto significativo no desempenho do

sistema, especialmente à medida que a taxa de chegada aumenta. A política Round-Robin apresentou tempos médios de resposta menores que a escolha aleatória, enquanto a política de escolha da fila mais curta apresentou os menores tempos médios de resposta entre as políticas avaliadas. Essa diferença tornou-se mais evidente para taxas de chegada próximas à capacidade de atendimento do sistema, quando o desequilíbrio na distribuição das requisições passa a ter maior impacto no tempo de espera.

Por fim, a verificação por meio da Lei de Little mostrou consistência entre o número médio de requisições no sistema, a vazão e o tempo médio de resposta obtidos na simulação. Dessa forma, os experimentos permitiram não apenas comparar as políticas de balanceamento, mas também validar os resultados da simulação por meio de um modelo analítico e de uma relação fundamental da teoria de filas.

APPENDIX A CÓDIGO DA SIMULAÇÃO

Você pode encontrar o código para rodar a simulação e um breve guia de como rodá-la no seguinte repositório do GitHub: MC714_Lab01.

APPENDIX B DIVISÃO DE TRABALHO

Para este trabalho, ambos os membros do grupo participaram da criação do relatório e do código da simulação, sendo que a maior parte da produção foi em conjunto, mas para fins de atribuições, as partes que cada membro ficou responsável foram:

A. Rafael Carro Gaudim

- Código de simulação de Servidores/Requests
- Suíte de Testes para a simulação
- Código para gerar gráficos e tabelas a partir das métricas
- Seção Resumo do Relatório
- Seção Arquitetura do Relatório
- Seção Conclusão do Relatório

B. Douglas Henrique Pereira

- Código de simulação do Load Balancer
- Código para tirar métricas da simulação
- Seção Modelagem do Relatório
- Seção Comparação do Relatório
- Seção Conclusão do Relatório